

YEAR 2025/2026



FINAL YEAR PROJECT

Climate Stress Testing in Corporate Banking : Scenario-Based Assessment of
Credit Rating Migration Risk and Sectoral Contagion

Authors

Céleste NENEHIDINI
Ikram DRINE
Mariane ALAPINI

Supervised by :

Charles-Emmanuel PROST

Table des matières

Abstract	v
Glossary	vi
Introduction	1
1 Literature Review	3
2 Clarification of theoretical concepts	6
2.1 Probability of default, rating migrations	6
2.2 The CreditMetrics model	7
2.3 Climate scenarios and application to credit risk	8
2.4 The Model Averaging	9
2.4.1 Bayesian Model Averaging (BMA)	9
2.4.2 Bayesian Averaging of Classical Estimates (BACE)	11
2.4.3 Stacking et agrégation prédictive des modèles	12
2.5 Le modèle GVAR	13
2.5.1 Tests préalables à l'estimation	13
2.5.2 Principe général du GVAR	15
2.5.3 Analyse de la propagation des chocs par GIRFs	16
2.5.4 Effets marginaux des variables macroéconomiques exogènes	17
2.5.5 Décomposition de la variance des erreurs de prévision (FEVD)	18
3 Exploratory Data Analysis	19
3.1 Rating data	19
3.2 Macroeconomic data	23
3.3 NFGS data	23
4 Extraction of Sectoral Systemic Risk Factors under the CreditMetrics Framework	24
4.1 Data Preprocessing	24
4.2 Sectoral Credit Migration Dynamics : PIT and TTC Estimation	25
4.3 Derivation of TTC-Based Migration Thresholds	26
4.4 Extraction of the Sectoral Systemic Factor	27
4.5 Validation du modèle	29
4.5.1 Vérification des probabilités PIT	29
4.5.2 Distribution du facteur systémique	30
5 Traitement des variables macroéconomiques	31
5.1 Choix des variables macroéconomiques	31
5.2 Stationnarisation des séries	32
5.3 Tests de stationnarité	33
6 Modèles satellites et stratégie de Model Averaging	34
6.1 Cadre général	34
6.2 Construction des modèles satellites candidats	34
7 Mise en oeuvre de la méthodologie	35
8 Regroupement des secteurs	vii

Liste des tableaux

1	Sector classification used in the rating dataset	21
2	Test de Kolmogorov–Smirnov pour la normalité de Z_t^s	31
3	Variables macroéconomiques américaines retenues	32
4	Correspondance entre codes NACE 17 et regroupements économiques	vii
5	Variables stationnaires retenues	viii

Table des figures

1	Exploratory analysis of the historical credit rating data.	20
2	Distribution of rating categories by sector.	22
3	Geographical and institutional structure of the dataset.	22
4	Average Through-the-Cycle (TTC) Transition Matrix — Financial Sector in Europe . . .	25
5	Migration threshold matrix (TTC) — finance sector	27
6	CreditMetrics migration thresholds (TTC) — finance sector, initial rating BBB	27
7	Estimated sectoral systemic risk factors (Z) in America, 2011–2024	28
8	Probabilités PIT observées vs reconstruites – Secteur finance	30
9	Distribution empirique du facteur Z_t^s – secteur finance	30
10	QQ-plot du facteur Z_t^s – secteur finance	31

Abstract

Glossary

Introduction

Credit risk has always been the main vulnerability factor in the banking system. Credit risk is the probability that a borrower will be unable to repay its debts, resulting in a loss for the lender. The banking intermediation model, which transforms deposits into loans, naturally exposes banks, their assets and their regulatory capital to credit risk. The fundamental parameters of credit risk, namely probability of default (PD), loss given default (LGD) and exposure at default (EAD), also form the basis of internal models, prudential standards (Basel II/III) and accounting standards such as IFRS 9 applied within banks.

The assessment of default risk is generally based on macroeconomic characteristics (growth, interest rates, unemployment), financial characteristics (profitability) and sectoral characteristics. However, today's economic environment is characterised by the emergence of a major structural factor : climate change. This is generating new sources of risk for corporate solvency and the quality of bank portfolios.

The effects of climate change can be divided into two types of risk. Physical risks are the first type of risk, due to the increase in the frequency and intensity of extreme events (floods, droughts, heat waves, sea level rise). They can directly damage means of production, make product design more expensive, disrupt supply chains and reduce the profitability of exposed businesses. Transition risks, on the other hand, arise from the transition to a low-carbon economy. These include changes in environmental regulations, the introduction of carbon pricing, technological innovations and shifts in consumer preferences. These developments are likely to undermine the economic models of carbon-intensive sectors. However, climate risk cannot be considered a separate risk category, but rather a factor that amplifies existing financial risks (particularly credit risk). It therefore influences the earnings trajectories, financial structure and growth prospects of borrowing companies. As such, ignoring this dimension amounts to underestimating the future distribution of credit losses, particularly in the medium and long term.

This awareness has led to rapid changes in prudential regulations. European authorities, notably the European Central Bank and the European Banking Authority, expect financial players to integrate climate risks into their risk management systems and stress tests. The scenarios developed by the Network for Greening the Financial System (NGFS), which provide a forward-looking framework for assessing the macroeconomic and sectoral impact of climate and transition trajectories, have become benchmarks. Financial institutions must therefore succeed in translating these trajectories into quantifiable impacts on credit risk parameters, and in particular on the specific default probabilities for each sector for each projection horizon.

However, this integration raises several methodological considerations. On the one hand, it takes a long time for these climate effects to materialise when credit risk models are built on the basis of short historical data and following a cyclical structure. On the other hand, the impacts result from mechanisms involving the dissemination of heterogeneous effects across sectors of activity, interdependence across value chains, and macroeconomic assumptions. Finally, the macroeconomic variables extracted from the forward-looking scenarios are exogenous and must be incorporated into an econometric framework capable of providing us with a model of the dynamic links between these impacts and the behaviour of actors across sectors.

This is the context for the present study. Its aim is to assess the extent to which climate risks, through the macro-sectoral scenarios defined by the NGFS, influence the dynamics of credit rating migration and corporate defaults, taking into account their sectoral interdependencies. More specifically, the question we seek to answer is :

How can the variables provided by climate scenarios be rigorously and consistently integrated into sectoral credit risk modelling in order to quantify the impact of the occurrence of risks, whether physical or transitional, on the probabilities of default in a climate stress test framework ?

To answer this question, we adopt a multi-step approach. First, we extract a systemic risk factor from the rating migration matrices, drawing inspiration from a methodology similar to CreditMetrics in order to capture the common share of sectoral credit dynamics that characterise them. We then formulate the interactions between the different sectors using a GVAR model, which allows us to describe the exogenous variables that interest us in this climate scenario study. This enables us to understand the transmission of climate shocks between sectors and measure their marginal effects on the distribution of future default risk.

1 Literature Review

The integration of climate risks into banking risk management is part of a relatively recent regulatory trend, but one that is now shaping prudential supervision. Initially absent from traditional credit risk management frameworks, climate change risks have gradually been recognised as potential sources of systemic financial risk, capable of affecting the solvency of counterparties, the value of collateral and, ultimately, the stability of the banking system.

This movement has accelerated following the explicit recognition of climate risks as material financial risk factors, notably through changes in accounting standards (IFRS 9), the Basel prudential approach based on a forward-looking view of credit risk, and the work of macroprudential authorities. These frameworks now encourage financial institutions to adopt a forward-looking approach, incorporating plausible adverse macroeconomic scenarios, which explicitly include climate scenarios.

In this context, climate stress testing has emerged as a key tool. Unlike traditional macro-financial stress tests, it aims to assess the impact of climate shocks – whether physical (extreme events, rising temperatures, precipitation) or transitional (climate policies, carbon taxation, energy transition) – on the quality of bank assets and prudential ratios. However, the specific nature of climate risks poses major methodological challenges, particularly in relation to the long-time horizon, the profound uncertainty surrounding scenarios and the multiple transmission channels.

The methodological frameworks recommended by regulators are mainly based on top-down approaches, in which climate scenarios are translated into macroeconomic shocks and then transmitted to banking risk indicators via satellite models on default probabilities, losses given default and exposures. This approach allows for consistent implementation across the financial system, but relies on aggregate assumptions that may mask significant sectoral or geographical heterogeneities.

At the same time, a growing body of literature is using microeconomic approaches, drawing on company-level or loan-level data to better capture the diversity of exposures to climate risks. These approaches make it possible to identify differentiated effects according to sector, carbon intensity, geographical location and the financial structure of borrowers.

However, regardless of the approach taken, one key issue remains : the ability of models to represent sectoral and macroeconomic interdependencies, as well as the propagation effects of climate shocks in the real economy and the financial system. It is precisely on this point that recent empirical literature highlights certain limitations of traditional frameworks.

Early empirical work focused mainly on physical risks, studying the impact of extreme weather events on the probability of borrower default. Boros's (2020) study of the main players in the Hungarian financial model highlights the difficulties involved in accurately identifying climate shocks and their macroeconomic transmission channels. It highlights the need to adapt traditional banking risk models to incorporate these new sources of vulnerability.

In line with this, Zanin, Calabrese and Thorburn (2024) propose a climate stress test framework applied to mortgage loans in the United States, based on a dynamic survival analysis. By constructing a climate

damage index based on tropical cyclone wind speeds, the authors show that geographical exposure plays a decisive role in the evolution of default probability. The results indicate that an extreme event with a very low probability (1,000-year return period) can increase the probability of default by nearly nine percentage points, or even up to 20% in the absence of insurance coverage, thus highlighting the importance of risk mitigation mechanisms.

Similar conclusions emerge in different geographical contexts. Romero, Salinas and Talledo (2024) developed a climate stress test for the Peruvian financial system, focusing on the effects of heavy rainfall and droughts. Their microeconomic approach shows that climate impacts on the probability of default vary greatly across sectors and regions, with the agricultural, commercial and transport sectors being particularly vulnerable.

Finally, Umar et al. (2025) extend this analysis to developing economies, studying the case of Pakistan. By linking temperature variations to macroeconomic and credit risk indicators, they highlight a significant deterioration in the quality of bank portfolios, particularly in water-intensive sectors such as textiles. These results confirm that physical risks are a major source of vulnerability for banking systems exposed to climate hazards.

At the same time, a wealth of literature has developed around the transition risks associated with the implementation of ambitious climate policies. Várgedő (2022) proposes a climate stress test focused on a carbon price shock in the Hungarian banking system. Using a sectoral network derived from an input-output table, the author shows that the effects of the shock spread beyond the directly exposed sectors, with significant increases in the probability of default in the energy sectors.

Comparable results are obtained by Aiello and Angelico (2022), who analyse the impact of different carbon taxes on the default rates of Italian companies. Their counterfactual analysis reveals that, although the average effects remain moderate in the short term, the impacts are highly heterogeneous across sectors and increase with the intensity of the carbon tax.

On a more aggregate scale, Gross et al. (2025) develop a stress test framework for the German banking sector, combining a macroeconomic and microeconomic approach. They show that the potential losses associated with the green transition are far from negligible and highlight a significant risk of sectoral concentration in loan portfolios.

Finally, the Bank of Japan's analysis (2023) emphasises the importance of inter-industry spillovers, showing that carbon price shocks spread indirectly throughout the economy via sectoral linkages, thereby affecting the credit cost ratios of banks, even those with low exposure to carbon-intensive sectors.

Beyond assessing potential losses, some studies focus on the behavioural effects induced by climate stress tests themselves. De Cicco, Gschossmann and Kok show that banks' participation in the 2022 climate stress test led to a significant reduction in the supply of credit to high-emitting companies, particularly from banks that are most advanced in climate risk management. Their study is based on the difference-in-difference method using detailed data on individual bank loans in the euro area. These results suggest that climate stress tests can influence credit decisions, even in the absence of explicit prudential constraints.

While most empirical work relies on satellite models or general equilibrium approaches, few studies

explicitly incorporate dynamic international and sectoral interdependencies in a systematic manner. It is precisely on this point that GVAR models make a major methodological contribution.

The seminal work of Han and Ng (2011) shows that GVAR models can effectively capture international macroeconomic interdependencies and improve forecasting performance. In a financial context, Croci Angelini et al. (2016) use a GVAR to analyse the contagion effects of sovereign spreads in the eurozone, highlighting different propagation mechanisms between core and peripheral countries. These contributions suggest that GVAR is a particularly suitable tool for analysing climate stress tests, as it allows for the explicit modelling of sectoral and macroeconomic interdependencies, captures the propagation and feedback effects of climate shocks, and coherently integrates exogenous scenarios from the Network for Greening the Financial System (NGFS).

In this perspective, the present project is fully in line with recent developments in the literature, proposing an approach combining climate stress testing and GVAR modelling in order to overcome the limitations of traditional frameworks and better represent the systemic nature of climate risks for the banking sector.

2 Clarification of theoretical concepts

This section aims to introduce and justify the theoretical concepts used in the various stages of the study, namely : modelling credit rating migration, projections under NGFS climate scenarios, and taking sectoral interdependencies into account using a GVAR model.

2.1 Probability of default, rating migrations

Probability of default (PD) is a central element in credit risk modelling. The literature generally distinguishes between two complementary concepts : default probabilities *Through-the-Cycle* (TTC) and *Point-in-Time* (PIT) C. EDER 2022.

PD PITs reflect the probability of default conditional on the information available on a given date.

They change over time depending on economic conditions and tend to increase during periods of economic recession. The PD PIT of entity i is defined by :

$$PD_i^{PIT}(z) = E[y_i | Z = z] = P(y_i = 1 | Z = z). \quad (1)$$

where Z denotes a systemic factor representing the economic climate at time t , and y_i is an indicator variable taking the value 1 in the event of default by entity i .

Conversely, PD TTC correspond to average probabilities calculated over a complete economic cycle. They are assumed to be fairly stable over time and not very sensitive to short-term fluctuations linked to the economic climate. Formally, a PD TTC corresponds to the expectation of the PD PIT over all realisations of the systemic factor :

$$PD_i^{TTC} = E_Z[PD_i^{PIT}(Z)] = E[y_i] = P(y_i = 1). \quad (2)$$

Once the probability of default has been defined, changes in borrowers' credit risk profiles are generally modelled using rating migration matrices. These matrices describe the probabilities of a borrower transitioning between different rating classes over a given horizon, including default. The modelling of rating migrations is most often based on Markov chains, characterised by the so-called *memoryless* property. This assumption implies that the probability of occupying a future state depends only on the present state, and not on the complete history of past ratings. Formally, if $R_t \in \{1, \dots, K\}$ denotes the rating class of a borrower at time t , the Markov property of order 1 is written as :

$$P(R_{t+1} = j | R_t = i, R_{t-1}, \dots) = P(R_{t+1} = j | R_t = i), \quad (3)$$

for all $i, j \in \{1, \dots, K\}$.

The model is said to be homogeneous if the transition matrix is constant over time. This is typically the case for TTC models. In the context of climate stress tests, this homogeneity assumption is often relaxed to allow migration probabilities to vary according to projected economic and climate conditions.

Transition probabilities are grouped together in a migration matrix $\mathbf{P} = (p_{ij})_{1 \leq i, j \leq K}$, where each element

$$p_{ij} = P(R_{t+1} = j \mid R_t = i) \quad (4)$$

represents the probability of migrating from class i to class j over a given period, usually annually. The default status is included as an absorbing state in the chain.

Finally, to project migration over multiple horizons, the homogeneity property allows Chapman-Kolmogorov's fundamental relation to be applied : the transition matrix for a period is obtained by multiplying the transition matrices for shorter periods.

In the context of this project, modelling rating migration represents an essential methodological approach. More specifically, the transition from a homogeneous TTC-type framework to a conditional PIT-type framework makes it possible to explicitly integrate the dependence of migration probabilities on anticipated macroeconomic and climate factors.

2.2 The CreditMetrics model

The CreditMetrics model, which was originally developed by J.P. Morgan, is based on the idea that credit rating changes result from the discrete realisation of a continuous latent process that describes the evolution of a borrower's credit quality. This evolution is represented by a latent variable X , assumed to follow a standard normal distribution, whose realisations are divided into intervals corresponding to different rating categories, including default. The observed transition matrices can therefore be understood as the result of a binning mechanism applied to this continuous variable.

In this framework, the probability of transition from an initial rating G to a final rating g is given by :

$$P(G, g) = \Phi(x_{g+1}^G) - \Phi(x_g^G), \quad (5)$$

where $\Phi(\cdot)$ denotes the distribution function of the standard normal distribution and $\{x_g^G\}$ the thresholds defining the intervals associated with the ratings.

With this in mind, Belkin, Forest, and Suchower (BELKIN, FOREST et SUCHOWER 1998) propose a simplified representation of credit risk based on the introduction of a single systemic factor, denoted by Z , which reflects the overall state of the credit cycle. The latent variable X is then divided into an idiosyncratic component and a systemic component shared by all borrowers :

$$X = \sqrt{1 - \rho} Y + \sqrt{\rho} Z, \quad (6)$$

where Y and Z are two independent random variables following a standard normal distribution, and $\rho \in (0, 1)$ measures the proportion of the variance of X explained by the systemic factor.

The factor Z is considered a global indicator of aggregate credit conditions. Positive values are associated with favourable periods, marked by lower default rates and an increased probability of rating upgrades, while negative values signal periods of stress, with an increase in adverse migrations and defaults. The

authors present a method for estimating Z using annual transition matrices provided by rating agencies, based on minimising the quadratic difference between observed probabilities and those anticipated by the model as a function of Z .

Once assessed, this factor can be used to create conditional transition matrices illustrating consistent macro-financial scenarios such as a favourable, average or unfavourable year. This parameterisation thus provides a framework that is particularly well suited to credit risk stress testing exercises, facilitating the quantification of the impact of systemic shocks on migration probabilities, default rates and, ultimately, the value of credit portfolios. Although the share of variance explained by the systemic factor is limited at the individual level, its fluctuations lead to economically significant variations in transition probabilities, highlighting its essential role in aggregate credit risk analysis (BELKIN, FOREST et SUCHOWER 1998).

2.3 Climate scenarios and application to credit risk

The scenarios developed by the NGFS now constitute the reference framework for prospective climate risk modelling applied to the financial sector. They provide consistent trajectories up to 2050, and even 2100, for a wide range of climate, energy, macroeconomic and sectoral variables, including gross domestic product (GDP), inflation, energy prices and greenhouse gas emissions (NETWORK FOR GREENING THE FINANCIAL SYSTEM 2025). These trajectories are based on integrated assessment models (IAMs), which enable the interactions between climate and energy policies and economic activity to be represented jointly.

In recent literature, NGFS scenarios are widely used as an exogenous framework for conducting climate stress tests applied to bank credit risk. Several studies show that these scenarios make it possible to simultaneously disrupt the macroeconomic and sectoral determinants of credit risk, thereby capturing both the effects of physical risks and transition risks on the quality of credit portfolios (BANK et B. EDER 2021 ; LEEGSTRA 2023).

Methodologically, the most common approach is to use the macroeconomic trajectories from the NGFS scenarios as exogenous inputs in credit risk models. These trajectories are then translated into changes in default probabilities or rating migration matrices through econometric or structural relationships. This approach is used in particular by central banks and supervisory authorities, which use NGFS scenarios to assess the resilience of the banking system to long-term climate shocks (EUROPEAN CENTRAL BANK 2022 ; BANK OF ENGLAND 2021).

Several empirical studies show that disorderly or delayed transition scenarios lead to a significant deterioration in the credit risk profile (LEEGSTRA 2023). Nevertheless, there are several limitations associated with the use of NGFS scenarios. On the one hand, their trajectories are highly dependent on the assumptions underlying the integrated assessment models, which introduces significant uncertainty, particularly over the long term. Second, the scenarios do not directly provide measures of financial risk, but require a step of transmission to credit variables. These limitations justify the use of NGFS scenarios as an exogenous framework, combined with macro-financial models capable of translating these trajectories into measurable credit risk dynamics.

2.4 The Model Averaging

In stress tests and in accordance with IFRS 9, satellite models link macroeconomic factors to credit risk variables, typically PDs, migration rates, or loss indicators. Macroeconomic scenarios (historical and projected) are exogenous and feed into risk projections.

Let $s \in \{1, \dots, S\}$ denote a sector (or portfolio), and t a time index. We observe a sectoral risk variable $y_{s,t}$ (e.g. default rate, aggregate PD, etc.) and a macroeconomic vector $X_t \in R^p$ common to all sectors.

A key difficulty is that the choice of model – in particular, which macroeconomic variables to use, which transformation, which structure – has a strong influence on the projections. Selecting a single ‘winning’ model through tests or metrics (AIC/BIC, etc.) ignores the uncertainty surrounding the model and tends to underestimate the total uncertainty of the forecasts. In this section, we discuss solutions found in the literature to resolve these issues in the context of model averaging.

2.4.1 Bayesian Model Averaging (BMA)

One of the difficulties of statistical inference is the uncertainty associated with model selection. In practice, classical statistical analysis often proceeds by selecting a single model using criteria such as hypothesis testing, stepwise procedures or information criteria, and then performs inference as if this model were the true generator of the data. This approach ignores the uncertainty introduced by the model selection stage and frequently leads to overly confident and optimistic conclusions, underestimation of variances and poorly calibrated predictions. BMA offers a coherent response to this problem by explicitly incorporating model uncertainty into Bayesian reasoning.

The principle of BMA is not to base inference on a single model, but to average the quantities of interest across all plausible models, weighted by their posterior probability given the observed data. Let us consider a finite set of candidate models $\mathcal{M} = M_1, \dots, M_K$, observed data D , and a quantity of interest Δ (e.g. a prediction, a parameter or a function of parameters). The posterior distribution of Δ is then given by :

$$p(\Delta | D) = \sum_{k=1}^K p(\Delta | D, M_k), p(M_k | D). \quad (7)$$

This expression shows that the final inference results from a mixture of posterior distributions specific to each model, with each contribution weighted by the credibility of the corresponding model.

The posterior probabilities of the models are obtained by directly applying Bayes’ theorem at the model level. For a model M_k , we have :

$$p(M_k | D) = \frac{p(D | M_k), p(M_k)}{\sum_{l=1}^K p(D | M_l), p(M_l)}, \quad (8)$$

where $p(M_k)$ represents the prior probability of the model and $p(D | M_k)$ its marginal likelihood, also known as the integrated likelihood. This quantity plays a central role in BMA because it evaluates the overall ability of the model to explain the data, independently of any particular choice of parameters.

The integrated likelihood of a model M_k with parameter θ_k is defined by :

$$p(D | M_k) = \int p(D | \theta_k, M_k), p(\theta_k | M_k), d\theta_k. \quad (9)$$

It corresponds to an average of the conditional likelihood over the entire parameter space, weighted by the prior distribution of the parameters. This integration allows parametric uncertainty to be taken into account and naturally introduces a mechanism for penalising complexity. In many practical cases, the exact calculation of the integrated likelihood is difficult, if not impossible, to perform analytically. Several approximations have therefore been proposed in the literature. The Laplace approximation provides a general method for approximating integrals of this type and, under certain regularity assumptions, leads to the approximation of the Bayesian information criterion (BIC). This approximation is written as :

$$\log p(D | M_k) \approx \log p(D | \hat{\theta}_k, M_k) - \frac{d_k}{2} \log n, \quad (10)$$

where $\hat{\theta}_k$ is the maximum likelihood estimator, d_k is the number of free parameters in the model, and n is the sample size. The BIC can thus be interpreted as an asymptotic approximation of the integrated likelihood and allows for practical implementation of BMA in complex settings.

The BMA also provides closed expressions for the posterior moments of the quantities of interest. The posterior expectation of Δ is written as :

$$E[\Delta | D] = \sum_{k=1}^K E[\Delta | D, M_k], p(M_k | D), \quad (11)$$

and the posterior variance admits a natural decomposition into an intra-model component and an inter-model component :

$$\text{Var}(\Delta | D) = \sum_{k=1}^K \left[\text{Var}(\Delta | D, M_k) + \hat{\Delta}_k^2 \right] p(M_k | D) - (E[\Delta | D])^2, \quad (12)$$

where $\hat{\Delta}_k = E[\Delta | D, M_k]$. This decomposition highlights the fact that the BMA explicitly incorporates the uncertainty associated with parameter estimation and that associated with model selection.

From a computational point of view, the main difficulty with BMA lies in the potentially enormous size of the model space. When the set of models is too large to be exhaustively enumerated, various strategies have been proposed. The Occam's Window method consists of restricting aggregation to models that are sufficiently supported by the data relative to the best model, while eliminating unnecessarily complex models dominated by simpler models. Another widely used approach is Markov Chain Monte Carlo Model Composition (MC³), which constructs a Markov chain on the model space with the posterior distribution of the models as its stationary distribution. The posterior expectations are then approximated by Monte Carlo averages. Related methods include stochastic search variable selection and trans-dimensional MCMC algorithms.

Empirical applications of BMA cover a wide range of statistical models, including linear regression

with variable selection, generalised linear models, and Cox-type survival models. Empirical studies consistently show that BMA improves predictive performance and uncertainty quantification. In particular, the predictive distributions obtained by BMA are better calibrated and have coverage rates closer to nominal levels than those obtained from selected models.

Predictive performance is often assessed using proper scoring rules, in particular the logarithmic score, which directly measures the quality of predictive distributions. According to this criterion, Bayesian Model Averaging (BMA) frequently outperforms approaches based on the selection of a single model, especially when model uncertainty is substantial.

Despite its conceptual advantages, BMA has certain limitations. The results may be sensitive to the choice of prior distributions on both the parameters and the model space. The computational cost can also become significant in high-dimensional settings. In addition, approximations such as the Bayesian Information Criterion (BIC) may introduce finite-sample biases. Nevertheless, BMA remains a major theoretical reference for the rigorous treatment of model uncertainty. The article by Hoeting, Madigan, Raftery and Volinsky provides a foundational synthesis of this approach and continues to influence contemporary developments in Bayesian statistics and statistical learning.

2.4.2 Bayesian Averaging of Classical Estimates (BACE)

Afin de conserver l'idée centrale du BMA tout en limitant la dépendance aux spécifications a priori, les auteurs proposent une approche intermédiaire appelée *Bayesian Averaging of Classical Estimates* (BACE). Cette méthode peut être interprétée comme une approximation asymptotique du BMA dans laquelle l'information contenue dans les données domine celle du prior. L'objectif n'est plus d'effectuer une intégration exacte sur l'espace des paramètres, mais de dériver des pondérations de modèles cohérentes avec le raisonnement bayésien tout en s'appuyant sur des estimateurs classiques.

Dans le cadre du BACE, les estimations conditionnelles à chaque modèle sont obtenues par moindres carrés ordinaires. Pour un modèle M_j , l'estimateur des coefficients β est donc donné par l'estimateur OLS $\hat{\beta}_j$, et la qualité d'ajustement du modèle est résumée par la somme des carrés des résidus SSE_j . L'enjeu principal devient alors la construction de probabilités a posteriori approximatives des modèles, utilisées comme poids dans l'agrégation.

Sous des hypothèses de priors raisonnablement diffus et en considérant la limite dans laquelle l'information des données devient dominante, les auteurs montrent que les probabilités a posteriori des modèles peuvent être approximées par

$$p(M_j | y) \propto p(M_j) T^{-k_j/2} (\text{SSE}_j)^{-T/2}, \quad (13)$$

où k_j désigne le nombre de variables incluses dans le modèle M_j et T la taille de l'échantillon. Cette expression met en évidence un compromis entre qualité d'ajustement et complexité du modèle, analogue à celui introduit par le critère d'information bayésien (BIC). Les modèles mieux ajustés sont favorisés, tandis que les modèles fortement paramétrés sont pénalisés par un terme en degrés de liberté.

Les probabilités a posteriori approximatives sont ensuite normalisées sur l'ensemble des modèles consi-

dérés :

$$p(M_j | y) = \frac{p(M_j) T^{-k_j/2} (\text{SSE}_j)^{-T/2}}{\sum_i p(M_i) T^{-k_i/2} (\text{SSE}_i)^{-T/2}}. \quad (14)$$

Ces pondérations jouent le même rôle que les probabilités de modèles dans le BMA standard, mais leur calcul repose uniquement sur des quantités issues de l'estimation classique.

Une fois les poids de modèles obtenus, l'agrégation des estimations suit directement le principe du BMA. L'espérance a posteriori d'un coefficient β est donnée par

$$E(\beta | y) = \sum_j p(M_j | y) \hat{\beta}_j, \quad (15)$$

où $\hat{\beta}_j$ est l'estimateur OLS du coefficient dans le modèle M_j , avec la convention que $\hat{\beta}_j = 0$ lorsque la variable correspondante n'est pas incluse dans le modèle. De même, la variance a posteriori intègre à la fois l'incertitude intra-modèle et la dispersion des estimations entre modèles.

L'approche BACE conserve ainsi l'idée fondamentale du BMA, à savoir l'agrégation des inférences sur l'ensemble des modèles possibles, tout en limitant l'influence des choix a priori sur les paramètres. Elle fournit une méthode pragmatique et facilement interprétable pour des applications empiriques de grande dimension, dans lesquelles un BMA pleinement bayésien serait difficile à mettre en œuvre.

2.4.3 Stacking et agrégation prédictive des modèles

Le stacking vise à construire une prédiction agrégée en combinant directement les prédictions issues de plusieurs modèles, sans supposer qu'un modèle particulier est le véritable générateur des données. Contrairement au BMA, les poids associés aux modèles ne sont pas interprétés comme des probabilités de modèles, mais sont estimés de manière à optimiser un critère de performance prédictive. Le stacking se situe ainsi dans une logique fréquentiste et prédictive, complémentaire à l'approche bayésienne développée précédemment.

Considérons un ensemble de modèles prédictifs $\mathcal{M} = \{M_1, \dots, M_K\}$. Chaque modèle produit, pour une observation x_i , une prédiction $\hat{y}_i^{(k)} = M_k(x_i)$. Le stacking consiste à définir une prédiction agrégée de la forme

$$\hat{y}_i^{\text{stack}} = \sum_{k=1}^K w_k \hat{y}_i^{(k)}, \quad (16)$$

où les poids w_k sont estimés à partir des données. Ces poids sont généralement contraints à être positifs et à sommer à un, afin de garantir la stabilité de la combinaison.

Les poids du stacking sont obtenus en résolvant un problème d'optimisation fondé sur une fonction de perte prédictive (cross correlation, MSE, ...). En régression, une formulation classique consiste à minimiser l'erreur quadratique moyenne :

$$\min_{w_1, \dots, w_K} \sum_{i=1}^n \left(y_i - \sum_{k=1}^K w_k \hat{y}_i^{(k)} \right)^2, \quad (17)$$

sous des contraintes éventuelles sur les poids. Afin d'éviter le sur-apprentissage, les prédictions $\hat{y}_i^{(k)}$ utilisées

dans ce problème sont généralement obtenues par validation croisée, ce qui distingue le stacking d’une simple régression sur les sorties des modèles.

Dans une formulation probabiliste, chaque modèle M_k fournit une distribution prédictive conditionnelle $p_k(y | x)$. Le stacking consiste alors à construire une distribution prédictive agrégée sous la forme d’un mélange :

$$p_{\text{stack}}(y | x) = \sum_{k=1}^K w_k p_k(y | x), \quad (18)$$

où les poids sont choisis de manière à maximiser la log-vraisemblance prédictive sur les données :

$$\max_w \sum_{i=1}^n \log \left(\sum_{k=1}^K w_k p_k(y_i | x_i) \right). \quad (19)$$

Cette expression est formellement proche de la distribution prédictive du BMA, à la différence essentielle que les poids ne correspondent pas à des probabilités a posteriori de modèles, mais sont déterminés exclusivement par des considérations prédictives.

Ainsi, alors que le BMA et le BACE cherchent à intégrer l’incertitude de modèle dans un cadre probabiliste cohérent, le stacking privilégie l’optimisation directe des performances prédictives. Cette différence de philosophie explique pourquoi le stacking est particulièrement adapté à des contextes empiriques complexes, notamment lorsque les modèles de base sont très hétérogènes ou difficiles à intégrer dans un cadre bayésien pleinement spécifié. Le stacking peut dès lors être vu comme une extension naturelle de la logique d’agrégation développée précédemment, orientée vers la prédiction plutôt que vers l’inférence probabiliste sur l’espace des modèles.

Les approches d’averaging décrites ci-dessus sont essentiellement *univariées par secteur* : chaque secteur s est modélisé séparément, et les dépendances intersectorielles ne sont pas explicitement représentées. Dans un contexte de chocs systémiques, ces dépendances peuvent être essentielles, ce qui justifie le passage à des cadres de type GVAR, qui est présenté dans la section suivante.

2.5 Le modèle GVAR

Pour modéliser les interdépendances sectorielles et la propagation des chocs macroéconomiques et climatiques dans le cadre du stress test, notre approche repose sur l’adaptation du modèle *Global Vector Autoregressive* (GVAR), initialement développé par DEES et al. (2007), à un découpage sectoriel pertinent pour les portefeuilles corporate bancaires.

2.5.1 Tests préalables à l’estimation

Avant de procéder à l’estimation d’un GVAR, il est essentiel de vérifier l’existence d’interdépendances significatives entre les différentes unités considérées, ici les secteurs d’activité. En l’absence de telles interactions, l’estimation de modèles sectoriels indépendants serait suffisante et le recours à un cadre multivarié global ne se justifierait pas.

Un test classiquement mobilisé dans ce contexte est le test de corrélation des résidus de **Breusch–Pagan**, qui permet d'évaluer l'hypothèse d'indépendance des termes d'erreur entre équations sectorielles. L'idée sous-jacente consiste à estimer, dans un premier temps, un modèle individuel pour chaque secteur par moindres carrés ordinaires, puis à analyser la structure de corrélation des résidus obtenus.

Plus formellement, on considère la matrice de corrélation des résidus estimés, notée $R = \text{corr}(\hat{\varepsilon})$, où $\hat{\varepsilon}$ regroupe les résidus issus des estimations sectorielles sous l'hypothèse nulle d'absence de corrélation croisée. La statistique de test est définie comme :

$$BP = T \sum_{i=1}^m \sum_{j=i+1}^m r_{ij}^2,$$

où T désigne le nombre d'observations par équation, m le nombre de secteurs considérés et r_{ij} l'élément (i, j) de la matrice de corrélation des résidus.

Sous l'hypothèse nulle d'indépendance des erreurs, cette statistique suit asymptotiquement une loi du khi-deux, dont le nombre de degrés de liberté dépend du nombre de secteurs considérés. Une valeur élevée de la statistique conduit alors à rejeter l'hypothèse nulle, indiquant la présence de corrélations résiduelles significatives entre les équations sectorielles.

Le rejet de l'hypothèse d'indépendance constitue un argument en faveur de l'utilisation d'un cadre multivarié global, tel que le GVAR, qui permet de modéliser explicitement ces interdépendances et d'analyser la propagation des chocs d'un secteur à l'autre. À l'inverse, l'absence de corrélation significative suggérerait que les dynamiques sectorielles peuvent être étudiées de manière isolée, sans perte d'information substantielle.

Par ailleurs, la validité du cadre GVAR repose aussi sur d'autres hypothèses économétriques qu'il convient de tester. En particulier, l'approche GVAR suppose que les variables étrangères, construites comme des agrégats pondérés des autres secteurs, peuvent être considérées comme faiblement exogènes vis-à-vis des dynamiques sectorielles domestiques. Cette hypothèse conditionne la légitimité de l'estimation de modèles VAR-X sectoriels qui constituent les blocs élémentaires du GVAR.

Conformément à la littérature de référence, deux familles de tests sont mobilisées afin de valider cette hypothèse dans un cadre stationnaire, en l'absence de relations de cointégration explicites.

- Exogénéité de court terme (block exogeneity) : L'exogénéité de court terme des variables étrangères est évaluée en testant l'absence d'influence dynamique des variables domestiques sur ces dernières. Plus précisément, dans l'équation associée aux variables étrangères d'un secteur donné, on teste l'hypothèse nulle selon laquelle l'ensemble des coefficients associés aux retards des variables domestiques est nul. Ce test peut être conduit à l'aide de statistiques de Wald, de tests du multiplicateur de Lagrange (LM) ou de tests de rapport de vraisemblance. Le non-rejet de cette hypothèse indique que les variables étrangères ne réagissent pas, à court terme, aux chocs spécifiques au secteur considéré, ce qui conforte leur statut de variables faiblement exogènes dans le modèle VAR-X sectoriel.
- Causalité instantanée : En complément, la validité du cadre conditionnel repose sur l'absence de dépendance contemporaine entre les innovations associées aux équations domestiques et étrangères.

Cette hypothèse est testée en examinant la nullité de la covariance contemporaine des résidus entre ces deux blocs d'équations. Le non-rejet de l'hypothèse d'absence de corrélation instantanée suggère que les interactions contemporaines entre secteurs sont correctement capturées par la structure du modèle, sans remise en cause de l'exogénéité conditionnelle des agrégats étrangers. L'ensemble de ces tests permet ainsi de justifier l'estimation de modèles VAR-X sectoriels comme briques de base du GVAR, en assurant la cohérence du cadre économétrique retenu pour l'analyse des interdépendances sectorielles et de la propagation des chocs.

2.5.2 Principe général du GVAR

Le cadre GVAR permet de représenter un système composé de plusieurs unités interconnectées chacune décrite par un modèle VAR domestique, enrichi par des variables étrangères synthétisant l'environnement global. Contrairement à un VAR unique de grande dimension, le GVAR conserve une structure parcimonieuse tout en capturant les dépendances croisées entre unités.

Dans ce projet, chaque secteur économique $s = 1, \dots, S$ est assimilé à un bloc du GVAR. L'objectif est de modéliser la dynamique conjointe du facteur systémique de crédit sectoriel Z_t^s , de variables macro-financières et énergétiques sectorielles ou globales, tout en tenant compte des interdépendances réelles entre secteurs.

Pour chaque secteur s , on spécifie un VAR domestique de la forme :

$$x_t^s = a_0^s + \sum_{p=1}^P A_p^s x_{t-p}^s + \sum_{q=0}^Q B_q^s x_{t-q}^{*,s} + u_t^s,$$

où :

- x_t^s est le vecteur des variables domestiques du secteur s (incluant notamment le facteur de crédit Z_t^s),
- $x_t^{*,s}$ est le vecteur des variables étrangères sectorielles,
- u_t^s est un vecteur d'innovations.

Cette structure reprend directement celle proposée par DEES et al. (2007), en substituant aux pays des secteurs économiques.

Il convient de souligner que, dans le cadre des modèles satellites utilisés pour les stress tests macro-financiers et climatiques, la dynamique temporelle joue généralement un rôle secondaire par rapport à la dépendance transversale entre unités. En particulier, la littérature souligne que les modèles satellites sont le plus souvent spécifiés sous une forme essentiellement statique ou faiblement dynamique, les variables macroéconomiques étant considérées comme strictement exogènes et servant avant tout de canaux de transmission des scénarios de stress.

Dans cette optique, l'étape initiale du GVAR repose sur l'estimation de modèles sectoriels de type VAR-X, spécifiés séparément pour chaque secteur, dans lesquels les variables macroéconomiques exogènes alimentent directement la dynamique du facteur de crédit sectoriel. La présence de termes de retard dans la dimension temporelle n'est pas centrale dans ce cadre et peut être limitée, voire omise, sans remettre en

cause la cohérence économique du modèle satellite. L'élément clé réside en effet dans la prise en compte des interdépendances sectorielles, qui sont introduites à la seconde étape du GVAR via les variables étrangères sectorielles construites à partir des matrices entrées–sortie.

Les variables étrangères $x_t^{*,s}$ sont définies comme des moyennes pondérées des variables des autres secteurs :

$$x_t^{*,s} = \sum_{r \neq s} w_{sr} x_t^r,$$

où les poids w_{sr} proviennent des matrices entrées–sortie (input–output).

Chaque VAR sectoriel est estimé séparément, ce qui garantit la faisabilité économétrique même en présence d'un grand nombre de secteurs et de variables. Une fois les modèles sectoriels estimés, ils sont empilés pour former le système GVAR global :

$$G(L)X_t = C + \varepsilon_t,$$

où X_t est le vecteur empilé de toutes les variables sectorielles, $G(L)$ un polynôme matriciel en l'opérateur retard, et ε_t le vecteur global des innovations.

2.5.3 Analyse de la propagation des chocs par GIRFs

Afin d'analyser la dynamique des chocs sur les variables du GVAR, la méthodologie s'appuie sur les *Generalized Impulse Response Functions* (GIRFs) définies par KOOP, PESARAN et POTTER (1996). Contrairement aux IRFs classiques, les GIRFs ne nécessitent ni orthogonalisation des chocs ni hypothèses fortes sur l'ordre des variables, ce qui est particulièrement adapté au cadre GVAR.

Pour un choc $\varepsilon_t = \varepsilon_j^*$ affectant une variable donnée, la GIRF à horizon h est définie par :

$$\text{GIRF}_j(h) = E[X_{t+h} \mid \varepsilon_t = \varepsilon_j^*, \mathcal{F}_{t-1}] - E[X_{t+h} \mid \varepsilon_t = 0, \mathcal{F}_{t-1}].$$

Cette approche permet d'identifier :

- la réponse directe de chaque secteur à un choc climatique ou énergétique,
- la vitesse et l'amplitude de la transmission intersectorielle,
- les effets de second tour via les chaînes de valeur,
- l'impact dynamique sur les facteurs systémiques de crédit Z_t^s .

Il est important de distinguer clairement le traitement des chocs affectant les variables endogènes du GVAR de celui des chocs portant sur les variables macroéconomiques exogènes. Les fonctions de réponse impulsionnelle, qu'elles soient classiques (IRF) ou généralisées (GIRF), sont définies pour analyser la propagation d'un choc affectant une variable endogène du système, via les innovations des équations constituant la représentation VMA du modèle.

Dans notre cadre, les variables macroéconomiques issues des scénarios NGFS sont supposées strictement exogènes et n'appartiennent pas au système endogène du GVAR. Par conséquent, les GIRFs ne sont pas un outil approprié pour analyser l'impact direct d'un choc macroéconomique sur les facteurs de crédit

sectoriels. L'analyse de tels chocs requiert une approche différente, fondée sur le calcul des effets marginaux des variables exogènes.

2.5.4 Effets marginaux des variables macroéconomiques exogènes

Bien que les fonctions de réponse impulsionnelle ne soient pas applicables aux variables strictement exogènes, il demeure possible d'analyser la manière dont un choc affectant une variable macroéconomique se propage aux différents facteurs de crédit sectoriels, tout en tenant compte des interdépendances intersectorielles capturées par le GVAR.

Considérons la forme réduite du GVAR global, écrite sous la forme :

$$G(L)X_t = C + \sum_{\ell=0}^L \Gamma_{\ell} X_{t-\ell} + \varepsilon_t,$$

où X_t regroupe les variables endogènes sectorielles, et où Γ_{ℓ} désigne la matrice des coefficients associés aux variables macroéconomiques exogènes retardées de ℓ périodes.

L'effet marginal d'un choc sur une variable macroéconomique $X_{t-\ell}$ sur les variables endogènes Z_t est alors donné par :

$$\frac{\partial Z_t}{\partial X_{t-\ell}} = G^{-1} \Gamma_{\ell},$$

où G^{-1} correspond à l'inverse de la matrice structurelle du système. Cette expression peut être interprétée comme une matrice de Leontief inversée, analogue à celle utilisée dans l'analyse entrées-sortie, et qui capture les mécanismes de propagation indirecte entre secteurs.

En développant l'inverse de G sous forme de série, on obtient :

$$G^{-1} = \sum_{k=0}^{\infty} B_0^k,$$

où B_0 peut être interprétée comme une matrice de dépendance spatiale mesurant l'intensité des liens économiques directs entre secteurs, telle qu'elle est induite par les matrices entrées-sortie.

L'effet marginal peut alors être décomposé comme :

$$G^{-1} \Gamma_{\ell} = \sum_{k=0}^{\infty} B_0^k \Gamma_{\ell}.$$

Cette décomposition permet d'interpréter la propagation d'un choc macroéconomique comme une dynamique intersectorielle par ordre de voisinage : le terme $k = 0$ correspond à l'effet direct sur le secteur considéré, tandis que les termes $k = 1, 2, \dots$ capturent les effets indirects transitant par les secteurs voisins, puis par des chaînes de dépendance de plus en plus éloignées.

Contrairement aux IRFs ou GIRFs, qui décrivent une propagation temporelle des chocs endogènes, cette décomposition met en évidence une propagation essentiellement spatiale des chocs macroéconomiques. Pour chaque variable macroéconomique, on obtient ainsi, à chaque horizon ℓ , une dynamique de diffusion

intersectorielle du choc, conditionnée par la structure des interdépendances économiques.

2.5.5 Décomposition de la variance des erreurs de prévision (FEVD)

Un outil complémentaire à l'analyse par fonctions de réponse impulsionnelle dans le cadre des modèles VAR et GVAR est la décomposition de la variance des erreurs de prévision (Forecast Error Variance Decomposition, FEVD). Cet outil permet de quantifier, pour un horizon donné, la part de l'incertitude de prévision d'une variable endogène attribuable aux différents chocs affectant le système (CHUDIK et PESARAN 2014).

Dans le cadre du GVAR, on considère la représentation moyenne mobile vectorielle (VMA) du système global, obtenue à partir de la forme réduite :

$$X_t = \sum_{h=0}^{\infty} \Psi_h \varepsilon_{t-h},$$

où X_t est le vecteur des variables endogènes sectorielles, ε_t le vecteur des innovations, et Ψ_h les matrices de réponses dynamiques du système.

L'erreur de prévision à horizon H pour la variable i s'écrit alors comme une combinaison linéaire des innovations passées, et sa variance peut être décomposée en contributions associées à chacun des chocs du système. La FEVD mesure ainsi la proportion de la variance de l'erreur de prévision de la variable i à l'horizon H imputable au choc sur la variable j .

Afin de garantir l'invariance de la décomposition à l'ordre des variables et d'éviter toute orthogonalisation arbitraire des chocs, la FEVD est définie dans sa version généralisée, conformément à l'approche de Pesaran et Shin. La contribution du choc j à la variance de l'erreur de prévision de la variable i à l'horizon H est donnée par :

$$\text{FEVD}_{ij}(H) = \frac{\sum_{h=0}^{H-1} (e_i^\top \Psi_h \Sigma e_j)^2}{\sum_{h=0}^{H-1} e_i^\top \Psi_h \Sigma \Psi_h^\top e_i},$$

où e_i et e_j sont des vecteurs de sélection, et Σ désigne la matrice de covariance des innovations.

Dans un cadre sectoriel, la FEVD permet d'évaluer l'importance relative des chocs idiosyncratiques et intersectoriels dans la dynamique du facteur de risque de crédit. Une contribution élevée des chocs provenant d'autres secteurs indique une forte interdépendance sectorielle, tandis qu'une FEVD dominée par les chocs propres au secteur suggère une dynamique essentiellement idiosyncratique.

La FEVD constitue ainsi un outil complémentaire aux GIRFs : alors que ces dernières permettent d'analyser la trajectoire dynamique d'un choc spécifique, la FEVD offre une vision synthétique de l'origine de l'incertitude de prévision à différents horizons, en mettant en évidence le rôle systémique ou sectoriel des chocs dans le GVAR.

3 Exploratory Data Analysis

For the implementation of our project, several data sources were made available to us. Each dataset was used at a specific stage of the climate stress-testing process. In this section, we first present the rating data. We then describe the macroeconomic data. After that, we introduce the NGFS data, which include several climate scenarios. We also briefly present the international input–output tables, which were used to construct the GVAR model.

3.1 Rating data


We have historical credit ratings for 13,944 distinct firms which are initially classified into 18 sectors. The data cover the period from July 2010 to April 2024. The ratings were provided by five credit rating agencies : Egan-Jones Ratings Company, Standard Poor’s Ratings Services, Moody’s Investors Service, Japan Credit Rating Agency, and Fitch Ratings. As the ratings originate from different agencies, a harmonisation procedure was required. Although each agency uses its own methodology, their rating scales are broadly comparable. We therefore mapped the original ratings into a common scale ranging from AAA to D. This step ensures consistency across firms and over time. It also guarantees that the transition matrices used in the stress-testing framework are coherent and comparable.

Overall, seven rating categories are observed in the dataset :


- AAA : Very high credit quality. The probability of default is extremely low and the repayment capacity is very strong.
- A : The repayment capacity is sound. However, there is some sensitivity to adverse economic conditions.
- BBB : The repayment capacity is adequate, but there is clear vulnerability to deteriorating economic conditions.
- BB : The repayment capacity is weakened, with significant long-term vulnerability.
- B : The repayment capacity is weak, and vulnerability is high.
- CCC–C : High probability of default.
- D : Payment default.

Figure 1a shows how the number of observed ratings evolves over time for each category. The total volume of ratings increases strongly in the early years of the sample. It reaches high levels around 2017–2018 and again around 2020–2021. It declines towards 2019 certainly because of the Covid 19 crisis, and also at the end of the period. This drop is expected in part because 2024 only covers January to April, so the last year is not complete.

The cross-sectional distribution is shown in figure 1b. The dataset is concentrated in the middle of the rating scale. The most frequent category is **BBB** (26.6%), followed by **B** (22.5%) and **A** (20.4%). **BB** represents 18.9%. The tails of the distribution are smaller : **AAA** accounts for 5.0%, **CCC–C** for 6.1%, and **Default** for 0.5%.



(a) Number of observed ratings by category over time (July 2010–April 2024).



(b) Overall rating distribution in the dataset.

FIGURE 1 – Exploratory analysis of the historical credit rating data.

These descriptive results matter for the construction of the rating migration matrices. In fact, migration matrices are estimated from observed rating transitions between two dates. If a category has few observations (for example AAA, CCC-C, or Default), some transitions may be rare or even unobserved. This can lead to noisy transition probabilities. In practice, the strong concentration in BBB/BB/B means that most transitions will be estimated precisely in the middle of the scale.

We also conducted an analysis of the distribution of ratings by sector. First, here are the different sectors of activity of the firms included in the rating dataset.

TABLE 1 – Sector classification used in the rating dataset

Code	Sector of activity
KZ	Financial and insurance activities
C5	Manufacture of other industrial products
C3	Manufacture of electrical, electronic and computer equipment ; manufacture of machinery
RU	Other service activities
JZ	Information and communication
BZ	Mining and quarrying
LZ	Real estate activities
HZ	Transportation and storage
GZ	Wholesale and retail trade ; repair of motor vehicles and motorcycles
C1	Manufacture of food products, beverages and tobacco products
OQ	Public administration, education, human health and social work activities
CH	Basic metals and fabricated metal products, excluding machinery and equipment
C4	Manufacture of transport equipment
C2	Coke and refined petroleum products
IZ	Accommodation and food service activities
MN	Professional, scientific and technical activities ; administrative and support services
FZ	Construction
AZ	Agriculture, forestry and fishing

Figure 2 reveals substantial heterogeneity across sectors. Some sectors are mainly concentrated in speculative grades such as BB or B (for example, Information and communication, Accomodation and food servic). Others display a stronger investment-grade profile. Default shares also vary across sectors. This sectoral dispersion is central to our modelling strategy.






FIGURE 2 – Distribution of rating categories by sector.



(a) Number of distinct firms by country.



(b) Distribution of ratings by agency.

FIGURE 3 – Geographical and institutional structure of the dataset.

Figure 3a shows that a large share of firms has no specified country. Among identified firms, the United States represents the largest group by a wide margin. Other countries account for much smaller proportions. This geographical imbalance limits the relevance of country-level migration matrices. It therefore supports our decision to construct sector-based transition matrices. Macroeconomic variables are then introduced through the GVAR framework, which captures cross-sector and cross-country spillovers.

Figure 3b highlights the strong dominance of two rating agencies in the dataset. Egan-Jones Ratings Company and Standard & Poor's Ratings Services account for the majority of observations. The remaining agencies represent much smaller shares. This concentration justifies the harmonisation procedure described earlier. It also supports the use of a unified rating scale when estimating migration matrices.

It motivates the estimation of sector-specific migration matrices and the extraction of sectoral systematic risk factors. It also supports the use of a GVAR structure, which allows climate and macroeconomic shocks to propagate differently across sectors.

3.2 Macroeconomic data

3.3 NFGS data

4 Extraction of Sectoral Systemic Risk Factors under the CreditMetrics Framework

The objective of this stage is to extract, for each sector of activity, a *latent systemic risk factor* capturing the cyclical dynamics of credit risk. This factor is intended to summarize the macroeconomic and structural pressures that simultaneously affect firms within the same sector. It constitutes a central building block for the subsequent modelling and stress testing framework.

The extraction of the systemic factor is based on the observation of credit rating migrations across a broad panel of firms, following the methodological framework of portfolio credit risk models in the spirit of *CreditMetrics* 2.2. Within this approach, the time variation observed in rating transition matrices is interpreted as the manifestation of a common latent factor reflecting the state of the sectoral credit cycle.

4.1 Data Preprocessing

The dataset used for the extraction of the systemic factor is based on internal rating histories, which allow the observation of credit rating migrations over time at the firm level.

Firms are subsequently grouped into broad sectors of activity. Smaller sectors are aggregated according to an economic rationale (see Appendix 4). This sectoral consolidation serves a dual purpose.

First, it aims to cluster activities that are likely to react similarly to macroeconomic or climate-related shocks. For instance, the agricultural sector (AZ) and extractive industries (BZ) are combined into a single sector labelled *primary_extraction*. These activities exhibit strong dependence on climatic conditions and commodity price fluctuations. Similarly, several manufacturing subsections (C1 to C5 and CH), including food processing, refining, equipment manufacturing, and metallurgy, are aggregated into a unified *industry* sector. These activities share comparable sensitivity to business cycle dynamics, energy costs, and regulatory constraints associated with the energy transition.

Second, the aggregation addresses a statistical requirement : ensuring a sufficient number of observations within each sector to obtain robust and stable estimates of transition probabilities.

A temporal preprocessing step is also implemented to construct a dataset suitable for econometric analysis. The data are aggregated at a quarterly frequency. For each firm and each quarter, the last observed rating is retained. This choice mitigates noise arising from intra-quarter rating updates while preserving sufficient temporal granularity to capture cyclical variations in credit risk.

When transition matrices exhibit temporal discontinuities due to low volumes or occasional missing observations, a *forward-fill* procedure is applied to ensure continuity of the series. This approach maintains the dynamic consistency of estimated transition probabilities without introducing artificial information.

In addition, firms are segmented according to their geographic exposure into four groups : (i) Americas, encompassing the United States, Canada, and South America ; (ii) Europe, including European Union countries and the United Kingdom ; (iii) Japan ; and (iv) Rest of the World. This geographic classification is introduced to improve the modelling of sectoral dependencies.

4.2 Sectoral Credit Migration Dynamics : PIT and TTC Estimation

For each sector s and each date t , a transition matrix is estimated from the observed migration counts $N_{ij,t}^s$, where i denotes the initial rating class and j the destination class.

Point-in-time (PIT) transition probabilities are obtained through row-wise normalization : the number of firms migrating from rating i to rating j over period t is divided by the total number of exposures initially rated i during the same period.

$$\hat{P}_{ij,t}^{\text{PIT},s} = \frac{N_{ij,t}^s}{\sum_j N_{ij,t}^s}. \quad (20)$$

By construction, the resulting matrix is stochastic, as the probabilities across each initial rating class sum to one.

These PIT matrices reflect prevailing economic conditions at date t . They explicitly capture cyclical effects affecting credit quality, including periods of intensified downgrade risk or, conversely, phases of credit improvement.

From a long-term risk management perspective, a through-the-cycle (TTC) matrix is subsequently estimated as the time average of the PIT matrices over the full observation window :

$$\bar{P}_{ij}^{\text{TTC},s} = \frac{1}{T} \sum_{t=1}^T \hat{P}_{ij,t}^{\text{PIT},s}. \quad (21)$$

This aggregation isolates the structural component of rating migrations by smoothing out cyclical fluctuations.




FIGURE 4 – Average Through-the-Cycle (TTC) Transition Matrix — Financial Sector in Europe

Figure 4 displays the average TTC transition matrix for the finance sector. A strong concentration of probabilities along the main diagonal can be observed, reflecting the high persistence of credit ratings over time. Transitions are predominantly confined to adjacent rating classes, while migrations to default remain infrequent for the highest-rated exposures.

This structure is consistent with standard empirical findings in corporate credit risk : rating dynamics are generally gradual, and credit deterioration typically unfolds through successive downgrades rather than abrupt jumps to default.

4.3 Derivation of TTC-Based Migration Thresholds

Within the CreditMetrics framework, rating migrations are driven by the crossing of thresholds defined on a latent Gaussian variable representing the firm's underlying creditworthiness.

These migration thresholds are estimated using the TTC transition probabilities. For a given initial rating class i , cumulative TTC probabilities are first computed as

$$F_{i,k}^{\text{TTC},s} = \sum_{j \leq k} \bar{P}_{ij}^{\text{TTC},s}, \quad (22)$$

where $\bar{P}_{ij}^{\text{TTC},s}$ denotes the TTC probability of migrating from rating i to rating j within sector s .

Migration thresholds are then obtained by inverting the cumulative distribution function of the standard normal distribution :

$$c_{i,k}^s = \Phi^{-1} \left(F_{i,k}^{\text{TTC},s} \right), \quad (23)$$

where $\Phi^{-1}(\cdot)$ denotes the inverse cumulative distribution function of the standard normal distribution.

In other words, the barriers correspond to the standard normal quantiles associated with the cumulative TTC probabilities. By construction, these thresholds are time-invariant and sector-specific. They reflect the structural component of migration dynamics and provide the mapping between observed rating transitions and the latent credit quality variable.

Figure 5 presents the full set of estimated thresholds for the previous finance sector TTC transition matrix. Each row corresponds to an initial rating class, and each column to a possible destination state. The monotonic structure of the thresholds ensures an ordered partition of the latent credit quality space.




FIGURE 5 – Migration threshold matrix (TTC) — finance sector

Figure 6 provides a graphical illustration of these thresholds for an initial rating of BBB. The vertical lines represent the different migration barriers on the standard normal distribution. The area between two consecutive thresholds defines the region associated with a specific rating outcome. Default corresponds to the lower tail of the distribution, reflecting an extreme deterioration in latent credit quality.




FIGURE 6 – CreditMetrics migration thresholds (TTC) — finance sector, initial rating BBB

4.4 Extraction of the Sectoral Systemic Factor

Under the latent Gaussian specification, the firm's credit quality variable is modelled as

$$X_t^s = \rho_s Z_t^s + \sqrt{1 - \rho_s^2} \varepsilon_t, \quad (24)$$

where $Z_t^s \sim \mathcal{N}(0, 1)$ denotes the sector-specific systemic factor and $\varepsilon_t \sim \mathcal{N}(0, 1)$ an idiosyncratic shock, assumed independent of Z_t^s .

Within this framework, point-in-time (PIT) migration probabilities are expressed as functions of the TTC thresholds :

$$P_{ij,t}^{\text{PIT},s} = \Phi\left(\frac{c_{i,j}^s - \rho_s Z_t^s}{\sqrt{1 - \rho_s}}\right) - \Phi\left(\frac{c_{i,j-1}^s - \rho_s Z_t^s}{\sqrt{1 - \rho_s}}\right), \quad (25)$$

where $c_{i,j}^s$ are the TTC migration thresholds previously estimated. Under this specification, the only time-varying component is the systemic factor Z_t^s , which captures cyclical fluctuations in sectoral credit conditions.

The parameter ρ_s represents the fraction of variance explained by the systemic factor. It governs the sensitivity of rating migrations to common shocks and therefore determines the amplitude of cyclical variation in transition probabilities.

In line with regulatory practice, ρ_s is calibrated using the Basel correlation formula applicable to corporate exposures :

$$\rho(PD) = 0.12 \times \frac{1 - e^{-50 PD}}{1 - e^{-50}} + 0.24 \times \left(1 - \frac{1 - e^{-50 PD}}{1 - e^{-50}}\right). \quad (26)$$

This specification implies a decreasing relationship between the TTC probability of default and asset correlation : higher-quality obligors (with lower PDs) are assumed to be more sensitive to systematic risk. For each sector s , the parameter ρ_s is therefore determined using the sector's average TTC probability of default.

Given the TTC thresholds and the calibrated value of ρ_s , the systemic factor Z_t^s is recovered at each date t through numerical inversion of the model-implied PIT probabilities. In practice, this consists in identifying the value of Z_t^s that minimizes the discrepancy between observed PIT default rates and those implied by the latent Gaussian model.

The estimation is performed on a quarterly basis, yielding a time series of sector-specific systemic factors. These series provide a quantitative measure of the sectoral credit cycle and constitute the key input for the subsequent satellite modelling and climate scenario projections.




FIGURE 7 – Estimated sectoral systemic risk factors (Z) in America, 2011–2024

The graph 7 shows pronounced cyclical co-movements across sectors, with a sharp systemic downturn around 2019–2020 consistent with a broad macroeconomic shock (Covid19), followed by a strong rebound in 2021. Finance and extraction primaire exhibit higher volatility and deeper troughs compared to construction and industry, indicating greater sensitivity to systemic shocks. Post-2022 dynamics appear more heterogeneous, suggesting a partial decoupling of sectoral credit conditions.


3.5 Model Validation

3.5.1 Consistency of Reconstructed PIT Probabilities

The first validation step consists in comparing observed PIT transition probabilities with those reconstructed from the estimated systemic factor.

For each date t , transition probabilities are recomputed using the estimated value of Z_t^s , the TTC migration thresholds, and the calibrated parameter ρ_s . These model-implied probabilities are then compared with the empirically observed PIT probabilities derived directly from the data.

Figures 8a and 8b illustrate this comparison for two representative transitions in the finance sector. The overall temporal dynamics are satisfactorily reproduced by the model. Periods of credit stress, characterized by elevated downgrade intensities, are captured by the estimated systemic factor, although peak amplitudes are occasionally slightly underestimated.



4.5 Validation du modèle

4.5.1 Vérification des probabilités PIT

La première étape de validation consiste à comparer les probabilités PIT observées aux probabilités reconstruites à partir du facteur systémique estimé.

Pour chaque date t , les probabilités sont recalculées à partir de Z_t^s , des barrières TTC et du paramètre ρ_s . Elles sont ensuite confrontées aux probabilités effectivement observées.

Les figures 8a et 8b présentent cette comparaison pour deux transitions représentatives du secteur *finance*. La dynamique temporelle est globalement bien reproduite. Les phases de tension sont captées par le modèle, même si certaines amplitudes peuvent être légèrement sous-estimées.




FIGURE 8 – Probabilités PIT observées vs reconstruites – Secteur finance

Ces résultats confirment que le facteur systémique estimé restitue de manière satisfaisante la dynamique des migrations.

4.5.2 Distribution du facteur systémique

La seconde étape de validation porte sur la distribution du facteur Z_t^s . Sous l'hypothèse du modèle latent, ce facteur est supposé suivre une loi normale centrée réduite.

La figure 9 présente l'histogramme du facteur estimé pour le secteur *finance*, ainsi que la densité théorique d'une loi $\mathcal{N}(0, 1)$. La distribution apparaît globalement centrée et relativement symétrique.




FIGURE 9 – Distribution empirique du facteur Z_t^s – secteur finance

La figure 10 présente le QQ-plot correspondant. Les points s'alignent globalement sur la diagonale, ce qui suggère une bonne adéquation à la loi normale.




FIGURE 10 – QQ-plot du facteur Z_t^s – secteur finance

Afin de formaliser cette analyse, un test de Kolmogorov–Smirnov est réalisé. Les résultats sont présentés dans le tableau 2.

TABLE 2 – Test de Kolmogorov–Smirnov pour la normalité de Z_t^s

Statistique	Valeur
Statistique KS	0.0717
p -value	0.9346
Conclusion	Impossible de rejeter H_0 : normalité plausible

La p -value élevée ne permet pas de rejeter l’hypothèse de normalité aux seuils usuels. La moyenne estimée est proche de zéro et l’écart-type reste d’ordre un. Ces résultats sont cohérents avec le cadre latent gaussien retenu.

5 Traitement des variables macroéconomiques

5.1 Choix des variables macroéconomiques

L’analyse repose sur huit variables macroéconomiques américaines trimestrielles couvrant la période 2010–2025. Ces indicateurs ont été sélectionnés dans une perspective *forward-looking* cohérente avec les

exigences de la norme IFRS 9, qui impose l'intégration d'informations macroéconomiques prospectives dans l'évaluation du risque de crédit.

Les variables retenues capturent les principales dimensions macrofinancières susceptibles d'influencer la qualité du crédit, à savoir le cycle d'activité économique, la politique monétaire, les conditions financières, les marchés d'actifs, les pressions inflationnistes et le marché du travail.

Bien que certaines variables européennes aient été initialement disponibles, nous avons restreint l'analyse aux variables américaines afin de limiter la complexité computationnelle du *Model Averaging*, d'éviter une explosion combinatoire du nombre de modèles candidats et de maintenir une cohérence géographique avec les facteurs sectoriels étudiés.

TABLE 3 – Variables macroéconomiques américaines retenues

Variable	Unité	Dimension économique
Taux de croissance du PIB	%	Cycle économique
Taux d'intervention banque centrale	%	Politique monétaire
Taux de change effectif	Indice (2020 = 100)	Compétitivité externe
Prix des actions	Indice (2017 = 100)	Conditions financières
Prix de l'immobilier résidentiel	Indice (2015 = 100)	Effet richesse / collatéral
Taux d'inflation	%	Pressions nominales
Taux d'intérêt à long terme	%	Conditions de financement
Prix du pétrole	USD/baril	Choc d'offre
Taux de chômage	%	Marché du travail

5.2 Stationnarisation des séries

Les modèles dynamiques du modèle satellite et du GVAR nécessitent des séries stationnaires afin d'éviter les régressions fallacieuses et de garantir la validité des estimations. Plusieurs transformations ont été appliquées en fonction des caractéristiques de chaque variable.

Le filtre de Hodrick–Prescott (avec un paramètre de lissage $\lambda = 1600$ pour les données trimestrielles) a été utilisé afin d'extraire la composante cyclique (*gap*). Cette méthode a été appliquée au taux de chômage américain, au taux d'intérêt à long terme, aux prix immobiliers résidentiels ainsi qu'au taux de change effectif. Pour ces variables, le *gap* et, lorsque nécessaire, sa première différence ont été retenus.

Le taux directeur de la banque centrale a été transformé en première différence afin de capter les variations de politique monétaire plutôt que son niveau.

Les variables strictement positives — prix des actions, prix du pétrole et PIB — ont été transformées en logarithme afin de stabiliser la variance et de permettre une interprétation en termes relatifs. Le filtre de Hodrick–Prescott a ensuite été appliqué aux séries en logarithme. Pour le PIB, la première différence du *gap* a également été utilisée.

5.3 Tests de stationnarité

La stationnarité des séries transformées a été évaluée à l'aide de deux tests complémentaires :

— **Test ADF (Augmented Dickey-Fuller)** :

H_0 : présence d'une racine unitaire

— **Test KPSS** :

H_0 : série stationnaire

Une variable est retenue dès lors qu'elle satisfait au moins l'un des deux critères (rejet de H_0 pour l'ADF ou non-rejet pour le KPSS).

Les transformations finalement retenues sont synthétisées dans le tableau 5 (voir annexe). On observe que les variables en niveau pur sont rarement stationnaires, tandis que les transformations en *gap* ou en différence de *gap* présentent des propriétés de stationnarité plus robustes. Cette approche permet au *Model Averaging* de sélectionner endogènement la transformation macroéconomique la plus pertinente pour chaque secteur étudié.

6 Modèles satellites et stratégie de Model Averaging

6.1 Cadre général

Après l'extraction du facteur systémique sectoriel Z_t , l'étape suivante consiste à estimer un modèle satellite reliant ce facteur aux variables macroéconomiques sélectionnées sur la période historique.

Dans le cadre du modèle CreditMetrics, le facteur systémique est supposé suivre :

$$Z_t \sim \mathcal{N}(0, 1)$$

et être i.i.d. dans le temps. Cette hypothèse implique que les variables explicatives macroéconomiques utilisées pour modéliser Z_t doivent être stationnaires, afin d'éviter toute relation fallacieuse.

Le modèle satellite s'écrit :

$$Z_t = f(X_t) + \varepsilon_t$$

où :

- X_t désigne l'ensemble des variables macroéconomiques observées à la date t ,
- $f(\cdot)$ est une fonction paramétrique estimée sur données historiques,
- ε_t est un terme d'erreur supposé centré et non autocorrélé.

Dans notre approche, la fonction f est spécifiée comme une combinaison linéaire :

$$Z_t = \alpha + \sum_{k=1}^K \beta_k X_{k,t} + \varepsilon_t$$

6.2 Construction des modèles satellites candidats

L'objectif est d'estimer un ensemble de modèles alternatifs qui seront ensuite combinés via une approche de *Model Averaging*. Pour ce faire nous disposons de 18 variables macroéconomiques stationnaires et pour chacune, 3 retards supplémentaires (*lag* 2 à *lag* 4). Le nombre total de variables candidates est donc de 72

Nous avons ensuite estimé tous les modèles satellites contenant une à trois variables. Le nombre total de modèles estimés correspond au nombre de combinaisons possibles parmi 90 variables :

$$\binom{72}{1} + \binom{72}{2} + \binom{72}{3} = 72 + 2556 + 59\,640 = 62\,268 \text{ modèles}$$

7 Mise en oeuvre de la méthodologie

Références

- BANK, Michael et Bernhard EDER (2021). *A Review on the Probability of Default for IFRS 9*. SSRN Working Paper No. 3981339. URL : https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3981339.
- BANK OF ENGLAND (2021). *Results of the 2021 Climate Biennial Exploratory Scenario (CBES)*. Climate Stress Test. Bank of England. URL : <https://www.bankofengland.co.uk/-/media/boe/files/stress-testing/2022/results-of-the-2021-cbes.pdf>.
- BELKIN, Barry, Lawrence FOREST et Steve SUCHOWER (1998). “A One-Parameter Representation of Credit Risk and Transition Matrices”. In : *CreditMetrics Monitor* 1.3, p. 46-56. URL : <https://www.z-riskengine.com/media/hqtnwlmb/a-one-parameter-representation-of-credit-risk-and-transition-matrices.pdf>.
- CHUDIK, Alexander et M. Hashem PESARAN (mai 2014). *Theory and Practice of GVAR Modeling*. CESifo Working Paper 4807. CESifo.
- DEES, Stephane et al. (2007). “Exploring the International Linkages of the Euro Area : A Global VAR Analysis”. In : *Journal of Applied Econometrics* 22.1, p. 1-38. URL : <https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp568.pdf>.
- EDER, Christian (2022). “Revisiting the Dualism of Point-in-Time and Through-the-Cycle Credit Risk Measures”. In : *SSRN Electronic Journal*. Available at SSRN. URL : <https://ssrn.com/abstract=3981340>.
- EUROPEAN CENTRAL BANK (2022). *Climate Risk Stress Test*. Occasional Paper. European Central Bank. URL : https://www.bankingsupervision.europa.eu/ecb/pub/pdf/ssm.climate_stress_test_report.20220708~2e3cc0999f.en.pdf.
- KOOP, Gary, M. Hashem PESARAN et Simon M. POTTER (1996). “Impulse Response Analysis in Nonlinear Multivariate Models”. In : *Journal of Econometrics* 74.1, p. 119-147. DOI : 10.1016/0304-4076(95)01753-4. URL : <http://www.chenchuanglian.cn/wp-content/uploads/2024/09/GIRF1998.pdf>.
- LEEGSTRA, M. (2023). “The Influence of Climate-Related and Environmental Risks on Bank Loan Credit Migration”. Mém. de mast. Erasmus University Rotterdam. URL : <https://thesis.eur.nl/pub/70298/20230710-Final-Version-Master-Thesis-619305.pdf>.
- NETWORK FOR GREENING THE FINANCIAL SYSTEM (2025). *NGFS Climate Scenarios : Technical Documentation*. Version 2025, Technical Report. URL : <https://www.ngfs.net/system/files/2025-01/NGFS%20Climate%20Scenarios%20Technical%20Documentation.pdf>.

8 Regroupement des secteurs

TABLE 4 – Correspondance entre codes NACE 17 et regroupements économiques

Code	Description NACE 17	Regroupement économique
AZ	Agriculture, sylviculture et pêche	extraction_primaire
BZ	Industries extractives	extraction_primaire
C1	Fabrication de denrées alimentaires, de boissons et de produits à base de tabac	industrie
C2	Cokéfaction et raffinage	industrie
C3	Fabrication d'équipements électriques, électroniques, informatiques; fabrication de machines	industrie
C4	Fabrication de matériels de transport	industrie
C5	Fabrication d'autres produits industriels	industrie
CH	Métallurgie et fabrication de produits métalliques (hors machines et équipements)	industrie
FZ	Construction	construction_immo
LZ	Activités immobilières	construction_immo
GZ	Commerce; réparation d'automobiles et de motocycles	services
HZ	Transports et entreposage	services
IZ	Hébergement et restauration	services
JZ	Information et communication	info-com
KZ	Activités financières et d'assurance	finance
MN	Activités scientifiques et techniques; services administratifs et de soutien	services_pro
OQ	Administration publique, enseignement, santé humaine et action sociale	public
RU	Autres activités de services	public

TABLE 5 – Variables stationnaires retenues

Variable retenue	Transformation appliquée
US_GDP_Growth_Rate	Niveau (déjà stationnaire)
US_GDP_log	Logarithme
US_GDP_log_hp_gap	Log + gap HP
US_GDP_log_hp_gap_diff	Différence du gap HP
US_Long_term_interest_rate	Niveau
US_Long_term_interest_rate_gap	Gap HP
US_Long_term_interest_rate_gap_diff	Différence gap HP
US_Central_bank_Intervention_rate_policy_interest_rate_diff	Différence
US_Unemployment_rate_hp_gap	Gap HP
US_Unemployment_rate_hp_gap_diff	Différence gap HP
US_House_prices_residential_hp_gap	Gap HP
US_House_prices_residential_hp_gap_diff	Différence gap HP
US_Effective_exchange_rate_hp_gap	Gap HP
US_Effective_exchange_rate_hp_gap_diff	Différence gap HP
US_Equity_prices_log_hp_gap	Log + gap HP
US_Oil_price	Niveau
US_Oil_price_log	Logarithme
US_Oil_price_log_hp_gap	Log + gap HP